

Relatório de Tratamento das bases e traçagem KPIs

Entrega 2 – Projeto Interdisciplinar: Ciências de Dados

Caroliny Rossi Bittencourt – 24025959

Rafael Alves dos Santos Guimarães – 24025724

Duda Lucena Miguel – 24025889

Isadora Teixeira Santoma – 24026458

São Paulo – 2025

1 Introdução

Nesta etapa do projeto, foi conduzido o processo de **tratamento, padronização e integração das bases de dados** fornecidas pela empresa **PicMoney**. O objetivo principal consistiu em garantir a consistência estrutural das informações, corrigir formatos de campos, ajustar tipagens e preparar os dados para sua utilização em um ambiente de banco de dados adequado ao desenvolvimento do *dashboard* interativo.

Após a etapa de limpeza e uniformização, procedeu-se à **conversão das bases tratadas para um banco de dados** centralizado, criado com o propósito de servir como fonte única de consulta para as aplicações do projeto. Essa estrutura possibilitou a organização lógica das informações e o desenvolvimento de endpoints específicos para acesso controlado aos dados.

Paralelamente, este momento do trabalho também marcou a **definição e configuração das KPIs (Key Performance Indicators)** utilizadas nas análises de cada perfil de usuário do sistema. A partir dos estudos realizados sobre a composição e comportamento das bases, foram estabelecidos dois conjuntos de indicadores:

- **KPIs do perfil CEO:** voltadas à análise estratégica e comportamental dos usuários, lojas e cupons, abordando aspectos de frequência, engajamento e retenção;
- **KPIs do perfil CFO:** direcionadas à avaliação financeira e operacional das transações, incluindo métricas de liquidez, repasse e margem de receita.

Com essas etapas, consolidou-se o ambiente técnico necessário para a análise integrada dos dados e a geração de visualizações dinâmicas, garantindo que o *dashboard* pudesse refletir tanto a dimensão comportamental quanto a financeira do ecossistema estudado.

2 Tratamento das Bases de Dados

O processo de tratamento teve como objetivo padronizar formatos, corrigir inconsistências e preparar os dados para análise e desenvolvimento das KPIs do projeto. As intervenções foram realizadas individualmente em cada base, conforme descrito a seguir.

2.1 Base de Players

- **Ajuste de formato:** Conversão da coluna `data_nascimento` para o padrão ISO `aaaa-mm-dd` utilizando a função `pd.to_datetime()` com parâmetro `dayfirst=True`.
- **Correção etária:** Recalcular a coluna `idade` com base na data de nascimento e na data atual (`datetime.date.today()`), garantindo consistência entre ambos os campos.

- **Exportação final:** Salvamento da base tratada em `bases_tratadas/base_players.csv`, codificada em UTF-8-sig.

2.2 Base de Transações

- **Padronização temporal:** Conversão das colunas `data` e `hora` para os formatos `aaaa-mm-dd` e `hh:mm:ss`, respectivamente.
- **Normalização categórica:** Criação do dicionário `mapa_categorias` para classificar os estabelecimentos (`nome_estabelecimento`) em grupos funcionais (*Restaurante, Fast Food, Academia, Farmácia, etc.*).
- **Criação de nova coluna:** Inclusão do campo `categoria_estabelecimento` a partir do mapeamento definido.
- **Inserção de campo auxiliar:** Adição da coluna `nome_campanha`, replicando o valor de `id_campanha` com o intuito de testes e simulação de futuras integrações.
- **Limpeza de colunas:** Ajustes nos campos textuais (`produtos`) e remoção de possíveis ruídos.
- **Exportação final:** Base consolidada salva em `bases_tratadas/base_transacoes.csv`.

2.3 Base de Lojas

- **Padronização temporal:** Conversão da coluna `data_captura` para o padrão `aaaa-mm-dd`.
- **Reclassificação de tipos:** Criação de um dicionário auxiliar para mapear o `nome_loja` em tipos funcionais (*Supermercado, Papelaria, Eletrônicos, etc.*), posteriormente renomeado para `categoria_estabelecimento`.
- **Padronização de nomenclaturas:** Renomeação das colunas conforme o modelo unificado entre bases:
 - `numero_celular` → `celular`
 - `data_captura` → `data`
 - `tipo_loja` → `categoria_estabelecimento`
 - `nome_loja` → `nome_estabelecimento`
 - `endereço_loja` → `endereço_estabelecimento`
- **Exportação final:** Base tratada salva em `bases_tratadas/base_lojas.csv`.

2.4 Base de Simulação

- **Padronização temporal:** Conversão das colunas `data` e `data_ultima_compra` para o padrão `aaaa-mm-dd`.
- **Formatação de tempo:** Conversão da coluna `horario` para o formato `hh:mm:ss`.
- **Exportação final:** Base salva em `bases_tratadas/base_simulacao.csv`.

2.5 Síntese Geral

Após os tratamentos, todas as bases foram unificadas em termos de formato de data, nomenclatura e codificação, assegurando compatibilidade entre os datasets e consistência para o cálculo das KPIs nas etapas seguintes do projeto.

3 Processo de Estudo e Estruturação das Bases de Dados

Conforme detalhado no relatório da entrega anterior, onde foi realizada a análise da qualidade das bases fornecidas pela empresa, estabeleceu-se que cada base correspondia a um contexto de estudo distinto dentro do ecossistema da aplicação. Esses contextos foram definidos da seguinte forma:

- **Base de Players:** voltada à compreensão do perfil dos usuários cadastrados;
- **Base de Transações e Cupons:** relacionada ao comportamento de compra e uso de cupons nas lojas;
- **Base de Lojas:** responsável por caracterizar o perfil dos estabelecimentos e suas respectivas categorias;
- **Base de Simulação:** representando uma pesquisa de campo fictícia entre usuários e não usuários do aplicativo.

Durante a confecção do banco de dados para o backend, foi conduzido um processo de **engenharia reversa** com o objetivo de identificar as entidades principais e os relacionamentos entre elas no contexto geral do projeto. Esse processo permitiu desenhar uma estrutura conceitual de dados relacional, representada no seguinte diagrama:




Figura 1: Modelo conceitual ideal de banco de dados relacional (Engenharia Reversa).

Com base nessa estrutura, foram elaboradas *views* SQL que reproduziam o formato e as chaves lógicas das bases originais, criando um ambiente relacional adequado para consulta e integração entre tabelas.

Entretanto, devido à natureza das bases fornecidas — que foram geradas individu-

almente por *prompts* de inteligência artificial —, os dados contidos não apresentavam coerência relacional entre si. Assim, não foi possível preencher o modelo relacional completo de forma funcional.

Como alternativa técnica, foi implementado um **banco de dados não relacional** contendo quatro tabelas independentes, cada uma representando uma das bases tratadas. O processo consistiu em replicar a estrutura de colunas ajustada nas etapas de limpeza e padronização, inserindo os registros correspondentes em cada tabela. O resultado foi um banco unificado em formato .db, conforme o diagrama a seguir:




Figura 2: Modelo de banco de dados utilizado no backend (versão não relacional).

A partir dessa configuração, o backend foi estruturado em quatro *endpoints* principais, responsáveis por fornecer os dados em formato JSON:

- /api/players
- /api/lojas
- /api/transacoes
- /api/simulacao

Cada endpoint foi configurado para aceitar parâmetros de filtragem via URL, permitindo que os dados fossem processados diretamente no servidor. No frontend, desenvolvido em *Streamlit*, as requisições a esses endpoints foram encapsuladas em funções específicas e armazenadas em **cache com tempo de vida padrão de 1 hora**, conforme as boas práticas do framework para otimização de desempenho e redução do número de chamadas à API.

4 Definição e Estrutura das KPIs – Perfil CEO

As KPIs apresentadas a seguir foram desenvolvidas a partir das bases tratadas e integradas ao painel do perfil CEO. Cada métrica foi estruturada para permitir análise des-

critiva, temporal, categórica e comportamental dos players, das lojas e dos cupons capturados.

4.1 KPIs de Perfil dos Players

4.1.1 Distribuição de Players por Faixa Etária

- **Descrição:** Agrupa os jogadores conforme faixas etárias predefinidas (0–17, 18–24, 25–34, 35–44, 45–54, 55–64, 65+).
- **Eixo de análise:** Faixa etária.
- **Filtros disponíveis:** Nenhum (análise global dos dados).

4.1.2 Distribuição de Players por Sexo

- **Descrição:** Exibe proporção de jogadores por sexo, com categorização automática de valores ausentes como “Não informado”.
- **Eixo de análise:** Sexo.
- **Filtros disponíveis:** Nenhum.

4.1.3 Distribuição de Players por Faixa Etária e Sexo

- **Descrição:** Combina as dimensões de idade e sexo, apresentando um gráfico de barras agrupadas.
- **Eixos de análise:** Faixa etária (X) × Sexo (cor).
- **Filtros disponíveis:** Nenhum.

4.1.4 Métricas Etárias

- **Descrição:** Calcula medidas descritivas de idade — moda, média e mediana — para o conjunto de players.
- **Eixos de análise:** Estatísticas descritivas.
- **Filtros disponíveis:** Nenhum.

4.1.5 Distribuição Espacial de Players – Cidades e Bairros

- **Descrição:** Gera gráficos de barras horizontais com número de jogadores únicos por cidade ou bairro, considerando três contextos: moradia, escola e trabalho.
- **Eixos de análise:** Localização (cidade ou bairro) × Quantidade de players.

- **Filtros disponíveis:**
 - Tipo de cidade (*Moradia, Escola, Trabalho*);
 - Cidade específica (no caso dos bairros).

4.2 KPIs de Frequência de Capturas

- Todas as KPIs de frequência utilizam como variável base o número de **celulares únicos (players)** registrados em determinado período, permitindo alternância de modo de exibição (*valores absolutos, percentuais ou ambos*) e aplicação de filtros de **ano, mês, lojas e categorias**.

4.2.1 Frequência Diária de Capturas

- **Eixo de análise:** Dia do mês × Players únicos.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.2.2 Frequência Semanal de Capturas

- **Eixo de análise:** Semana do ano × Players únicos.
- **Filtros disponíveis:** Ano, loja, categoria, modo de exibição.

4.2.3 Frequência por Dia da Semana (Ano e Mês/Ano)

- **Eixo de análise:** Dia da semana × Players únicos.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.2.4 Frequência Mensal e Anual de Capturas

- **Eixos de análise:** Mês ou ano × Players únicos.
- **Filtros disponíveis:** Loja, categoria, modo de exibição.

4.2.5 Médias de Frequência

- **Descrição:** Calcula médias de capturas diárias, semanais, mensais e anuais.
- **Eixos de análise:** Tempo × Players únicos.
- **Filtros disponíveis:** Ano, mês, loja, categoria.

4.3 KPIs de Cupons

4.3.1 Distribuição por Tipo de Cupom

- **Descrição:** Exibe proporção de capturas por tipo de cupom (em gráfico de pizza).
- **Eixos de análise:** Tipo de cupom × Players únicos.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.3.2 Tipo de Cupom por Loja

- **Descrição:** Mostra a distribuição dos tipos de cupons agrupados por loja.
- **Eixos de análise:** Loja × Tipo de cupom.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.3.3 Tipo de Cupom por Categoria

- **Descrição:** Representa a proporção dos tipos de cupom agrupados por categoria de estabelecimento.
- **Eixos de análise:** Categoria × Tipo de cupom.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.4 KPIs de Comparativo de Lojas e Categorias

4.4.1 Lojas por Número de Capturas

- **Descrição:** Exibe o ranking de lojas conforme número de capturas únicas no mês/ano selecionado.
- **Eixos de análise:** Loja × Players únicos.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.4.2 Categorias por Número de Capturas

- **Eixos de análise:** Categoria × Players únicos.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.4.3 Número de Estabelecimentos por Categoria

- **Eixos de análise:** Categoria × Número de estabelecimentos distintos.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

4.4.4 Resumo de Parceiros

- **Descrição:** Retorna totais de lojas e categorias distintas no mês/ano analisado.
- **Eixos de análise:** Totais agregados.
- **Filtros disponíveis:** Ano, mês, loja, categoria.

4.5 KPIs de Retenção de Usuários

4.5.1 Taxas de Retenção (Diária, Semanal, Mensal e Anual)

- **Descrição:** Calcula taxa de usuários retidos entre períodos consecutivos (dia→dia, semana→semana, mês→mês, ano→ano).
- **Eixos de análise:** Período base × Período seguinte.
- **Filtros disponíveis:** Ano, mês, loja, categoria.

4.5.2 Retenção por Defasagem de Dias

- **Descrição:** Mede a taxa de retorno exato após k dias de uma primeira captura, com exibição opcional em percentual ou valores absolutos.
- **Eixos de análise:** Defasagem de dias × Taxa de retenção.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

5 Definição e Estrutura das KPIs – Perfil CFO

As KPIs do perfil CFO foram projetadas para fornecer uma visão financeira e operacional do ecossistema de transações, com foco em indicadores de liquidez, repasse e desempenho comercial. As métricas estão agrupadas conforme suas áreas funcionais: Transações, Liquidez e Repasse.

5.1 KPIs de Transações

5.1.1 GMV (Gross Merchandise Volume)

- **Descrição:** Soma total dos valores transacionados na base, identificando a movimentação financeira bruta do período.
- **Eixo de análise:** Valor total (R\$).
- **Filtros disponíveis:** Ano, mês, loja, categoria (via filtros universais do dashboard).

5.1.2 Número Total de Transações

- **Descrição:** Total de registros de transações realizadas no período analisado.
- **Eixo de análise:** Quantidade de transações.
- **Filtros disponíveis:** Ano, mês, loja, categoria.

5.1.3 Ticket Médio

- **Descrição:** Valor médio das transações, calculado pela razão entre o GMV e o número total de transações.
- **Eixos de análise:** Transações × Valor médio.
- **Filtros disponíveis:** Ano, mês, loja, categoria.

5.1.4 Percentual de Transações com Cupom

- **Descrição:** Percentual de transações que possuem cupom vinculado (`id_cupom` não nulo).
- **Eixo de análise:** Percentual sobre o total de transações.
- **Filtros disponíveis:** Ano, mês, loja, categoria.

5.1.5 Série Temporal de Transações

- **Descrição:** Gráfico de linha representando a variação diária no volume de transações.
- **Eixo de análise:** Dia × Número de transações.
- **Filtros disponíveis:** Período temporal.

5.1.6 Ranking de Estabelecimentos por Transações

- **Descrição:** Classificação dos estabelecimentos pelo número de transações registradas.
- **Eixos de análise:** Estabelecimento × Volume de transações.
- **Filtros disponíveis:** Top N (padrão: 15), período.

5.1.7 Mapa de Calor – Dia da Semana x Hora

- **Descrição:** Heatmap que cruza os eixos “dia da semana” e “hora” para identificar picos de atividade transacional.
- **Eixos de análise:** Dia da semana x Hora x Número de transações.
- **Filtros disponíveis:** Período.

5.2 KPIs de Liquidez

5.2.1 Receita Líquida

- **Descrição:** Calculada como diferença entre o valor da compra e o valor do cupom ($\text{receita_liquida} = \text{valor_compra} - \text{valor_cupom}$). Em cenários de fallback, considera-se $\text{receita_liquida} = \text{valor_cupom} - \text{repasse_picmoney}$.
- **Eixo de análise:** Valor monetário (R\$).
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo (valores absolutos ou percentuais).

5.2.2 Margem Líquida

- **Descrição:** Relação entre receita líquida e valor de compra ($\text{margem} = \text{receita_liquida} / \text{valor_compra}$). O cálculo se adapta automaticamente em casos de dados incompletos, utilizando fallback por cupom.
- **Eixo de análise:** Percentual de margem sobre receita.
- **Filtros disponíveis:** Ano, mês, loja, categoria, modo de exibição.

5.2.3 Top Lojas por Receita Líquida

- **Descrição:** Ranking das lojas com maior somatório de receita líquida, exibindo valores absolutos ou percentuais do total.
- **Eixos de análise:** Estabelecimento x Receita líquida.
- **Filtros disponíveis:** Top N (padrão: 15), modo (R\$ ou %).

5.2.4 Receita Líquida Diária

- **Descrição:** Evolução temporal da receita líquida por dia.
- **Eixos de análise:** Data x Receita líquida (R\$).
- **Filtros disponíveis:** Período.

5.2.5 Custo por Tipo de Cupom

- **Descrição:** Distribuição dos valores de cupom por tipo, representando o custo relativo de cada categoria de cupom.
- **Eixos de análise:** Tipo de cupom × Valor (ou percentual).
- **Filtros disponíveis:** Modo de exibição (percentual ou monetário).

5.2.6 Receita Líquida por Canal de Captação

- **Descrição:** Soma de receita líquida agrupada por canal de captação (`local_captura`), permitindo análise de eficiência operacional entre canais.
- **Eixos de análise:** Canal × Receita líquida.
- **Filtros disponíveis:** Modo (R\$ ou %).

5.2.7 Margem Líquida por Tipo de Cupom

- **Descrição:** Exibe a margem líquida percentual média por tipo de cupom, considerando apenas tipos com receita mínima (`min_receita` = 1000).
- **Eixos de análise:** Tipo de cupom × Margem líquida (%).
- **Filtros disponíveis:** Valor mínimo de receita, modo de exibição.

5.3 KPIs de Repasse

5.3.1 Valor Bruto de Cupons

- **Descrição:** Soma total de `valor_cupom`, representando o volume bruto gerado pelas operações.
- **Eixo de análise:** Valor total (R\$).
- **Filtros disponíveis:** Ano, mês, loja, categoria.

5.3.2 Repasse PicMoney

- **Descrição:** Soma total de `repasse_picmoney`, representando o valor destinado à plataforma.
- **Eixo de análise:** Valor (R\$).
- **Filtros disponíveis:** Ano, mês, loja, categoria.

5.3.3 Repasse ao Lojista

- **Descrição:** Valor líquido recebido pelos estabelecimentos, calculado como $\text{repass_lojista} = \text{valor_cupom} - \text{repass_picmoney}$.
- **Eixo de análise:** Valor monetário (R\$).
- **Filtros disponíveis:** Ano, mês, loja, categoria.

5.3.4 Take Rate

- **Descrição:** Percentual de retenção da plataforma, calculado como $\text{repass_picmoney} / \text{valor_cupom}$.
- **Eixos de análise:** Percentual (%).
- **Filtros disponíveis:** Período, loja, categoria.

5.3.5 Série Temporal de Repasse Lojista

- **Descrição:** Série de tempo da soma de repasses diários a lojistas.
- **Eixos de análise:** Data × Repasse lojista.
- **Filtros disponíveis:** Período.

5.3.6 Ranking de Estabelecimentos por Repasse

- **Descrição:** Classificação das lojas com maior valor total de repasse.
- **Eixos de análise:** Estabelecimento × Valor de repasse.
- **Filtros disponíveis:** Top N (padrão: 15), período.

5.3.7 Tabela Consolidada de Repasse

- **Descrição:** Tabela com agregações por loja, incluindo número de transações, valores brutos, repasse à plataforma, repasse ao lojista, ticket médio e take rate (%).
- **Eixos de análise:** Loja × Métricas financeiras agregadas.
- **Filtros disponíveis:** Loja, categoria.

5.3.8 Composição por Tipo de Cupom (Pizza)

- **Descrição:** Distribuição percentual do valor total de cupons por tipo.
- **Eixos de análise:** Tipo de cupom × Valor (R\$ ou %).
- **Filtros disponíveis:** Período.

5.3.9 Top Lojas por Valor de Cupons

- **Descrição:** Ranking das lojas com maior volume financeiro em cupons.
- **Eixos de análise:** Loja × Valor de cupom.
- **Filtros disponíveis:** Top N (padrão: 15).

5.3.10 Top Lojas por Valor de Repasse

- **Descrição:** Ranking das lojas com maior volume financeiro repassado.
- **Eixos de análise:** Loja × Valor de repasse.
- **Filtros disponíveis:** Top N (padrão: 15).

5.3.11 Top Lojas por Percentual de Repasse

- **Descrição:** Percentual médio de repasse por loja ($\text{repasse_lojista} / \text{valor_cupom}$), exibindo apenas lojas com volume mínimo ($\text{valor_cupom} \geq 1000$).
- **Eixos de análise:** Loja × Percentual de repasse.
- **Filtros disponíveis:** Valor mínimo, Top N.

6 Conclusão

A forma como as bases de dados de teste foram originalmente geradas comprometeu o estabelecimento de chaves de relacionamento entre as entidades, limitando a exploração analítica e a configuração de KPIs integradas. Em razão disso, as métricas desenvolvidas permaneceram segmentadas nos quatro contextos de estudo — usuários, transações, lojas e simulação — sem possibilidade de cruzamento relacional direto entre eles.

Ainda assim, o processo permitiu idealizar uma estrutura conceitual consistente, baseada nas colunas e padrões identificados em cada base. Com isso, compreende-se que, no *deploy* oficial do sistema, utilizando uma base real e relacional, será possível atingir um nível mais elevado de integração e leitura analítica dos dados, refletindo o comportamento genuíno do ecossistema.

Por fim, compreendeu-se que o escopo deste trabalho não incluía a interpretação ou extração de conclusões sobre os dados fornecidos, mas sim a **construção dos espaços analíticos** necessários para que os usuários finais da aplicação possam realizar suas próprias explorações e interpretações. Dessa forma, o projeto cumpre seu propósito central de disponibilizar uma infraestrutura de análise confiável, flexível e alinhada aos objetivos estratégicos da plataforma.